

Processos Não Estacionários

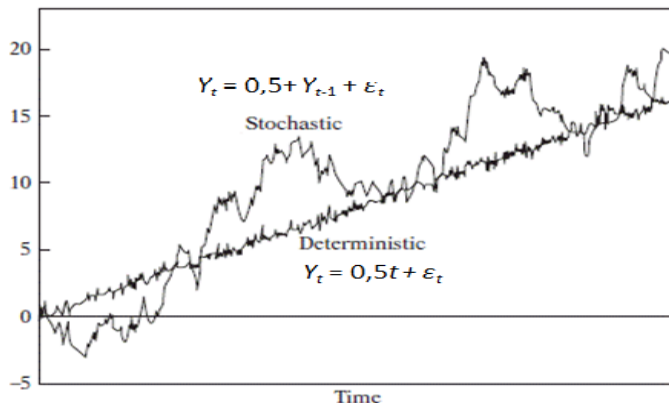
Testes de Raiz Unitária

Bibliografia Básica:

- Enders, W. *Applied Econometric Time Series*. Cap. 4.
- Bueno, R. L. S. *Econometria de Séries Temporais*. Cap. 4.
- Box, G.E., Jenkins, G. M., Reinsel, G.C. & Ljung, G. M.(2016). *Time series analysis: forecasting and control*. Cap. 4.
- Morettin, P. A. *Análise de Séries Temporais*. Cap. 5.

Processos Não Estacionários

Processo não estacionário é um processo cuja média e/ou variância serão dependentes do tempo.



Processos Estocásticos Integrados

Processo estocástico integrado: processo estocástico que pode se tornar estacionário por meio da diferenciação.

Se um processo se torna estacionário ao se tomar sua primeira diferença dizemos que este processo é integrado de ordem um, ou $I(1)$.

Se o processo somente se tornar estacionário na d -ésima diferença dizemos que este é um processo integrado de ordem d , ou $I(d)$.

Um processo que não precisa ser diferenciado para se tornar estacionário é integrado de ordem zero, ou $I(0)$.

Modelo *Random Walk* ou Passeio Aleatório

Um passeio aleatório é dado por:

$$Y_t = \delta + Y_{t-1} + \epsilon_t$$

em que $\epsilon_t \sim RB(0, \sigma_\epsilon^2)$. Se:

- $\delta \neq 0$: passeio aleatório com *drift* (ou **deslocamento** ou **tendência estocástica**). Neste caso, valor médio e variância são dependentes do tempo.
- $\delta = 0$: **tendência estocástica pura**. Neste caso, variância é dependente do tempo, ou seja,

$$E(Y_t) = E(Y_{t-1} + \epsilon_t) = \dots = E(Y_0 + \sum_{t=1}^T \epsilon_t) = Y_0$$

Temos que a esperança é constante e independe do tempo.

$$Var(Y_t) = E\{(Y_t - E(Y_t))^2\} = \dots = \sum_{t=1}^T \sigma_\epsilon^2 = T\sigma_\epsilon^2$$

A variância é, portanto, uma função crescente do tempo, logo o passeio aleatório não é um processo estacionário.

Como identificar se a série é ou não estacionária?

1. Análise gráfica

- Inspeção visual raramente permite distingui-la como de tendência estocástica ou tendência determinística

2. Função de autocorrelação:

- Séries não estacionárias: fortes correlações seriais

3. Teste de Raiz Unitária.

Teste de Raiz Unitária ou Teste de Estacionariedade

Considere o modelo:

$$Y_t = \rho Y_{t-1} + \epsilon_t$$

Raiz unitária: Quando temos que $\rho = 1$ aparece o problema de raiz unitária que, basicamente, é sinônimo de não estacionariedade.

Passeio aleatório, com ou sem drift, pode se tornar estacionário ao ser diferenciado, isto é:

$$Y_t = Y_{t-1} + \epsilon_t \Leftrightarrow \Delta Y_t = \epsilon_t$$

Exemplo

Considere a série de taxa de câmbio *Real/US\$*:

- a) Faça o gráfico da série e construa a função de autocorrelação;
- b) Tome a primeira diferença e construa a função de autocorrelação.

Testes de Raiz Unitária

Testes que abordaremos:

1. Testes Dickey Fuller
2. Teste Dickey Fuller Aumentado – ADF
3. Teste de Phillips Perron
4. Teste de KPSS
5. Teste de Dickey e Pantula
6. Teste com Quebra Estrutural - Quebra conhecida
7. Teste com Quebra Estrutural Desconhecida
8. Raízes Unitárias Sazonais

1. Teste Dickey Fuller – DF

Objetivo:

Testar a existência de 1 RU em Y_t quando o processo gerador da série for expresso por uma das expressões abaixo:

$$(1) \quad Y_t = \alpha + \beta t + \rho Y_{t-1} + \epsilon_t \quad \Rightarrow \quad \Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \epsilon_t$$

$$(2) \quad Y_t = \alpha + \rho Y_{t-1} + \epsilon_t \quad \Rightarrow \quad \Delta Y_t = \alpha + \gamma Y_{t-1} + \epsilon_t$$

$$(3) \quad Y_t = \rho Y_{t-1} + \epsilon_t \quad \Rightarrow \quad \Delta Y_t = \gamma Y_{t-1} + \epsilon_t$$

em que α e βt são componentes determinísticos, denominados constante ou *drift* e tendência linear, respectivamente; ϵ_t é um ruído branco.

Hipóteses nula e alternativa:

$$H_0 : \rho = 1 \Leftrightarrow \gamma = 0 \quad (1 \text{ RU})$$

$$H_1 : \rho < 1 \Leftrightarrow \gamma < 0 \quad (0 \text{ RU})$$

- Teste Monocaudal à esquerda

- Estatísticas dos testes são chamadas de:

1. Modelo com constante e tendência determinística: τ_τ
2. Modelo com constante: τ_μ
3. Modelo sem termos determinísticos: τ

Teste DF

Sob a hipótese nula, a distribuição do teste não é convencional, ou seja, não é igual à distribuição t , dado que Y_t não é estacionário.




FIGURE 4.7 The Dickey-Fuller Distribution

Dickey & Fuller (1979) recalcularam os valores críticos: Tabela A, p. 488, Enders (2010)

Empirical Cumulative Distribution of τ

Probability of a Smaller Value

Sample Size	0.01	0.025	0.05	0.10
-------------	------	-------	------	------

No Constant or Time ($\alpha_0 = \alpha_2 = 0$)

τ

25	-2.66	-2.26	-1.95	-1.60
50	-2.62	-2.25	-1.95	-1.61
100	-2.60	-2.24	-1.95	-1.61
250	-2.58	-2.23	-1.95	-1.62
300	-2.58	-2.23	-1.95	-1.62
∞	-2.58	-2.23	-1.95	-1.62

Constant ($\alpha_2 = 0$)

τ_{μ}

25	-3.75	-3.33	-3.00	-2.62
50	-3.58	-3.22	-2.93	-2.60
100	-3.51	-3.17	-2.89	-2.58
250	-3.46	-3.14	-2.88	-2.57
500	-3.44	-3.13	-2.87	-2.57
∞	-3.43	-3.12	-2.86	-2.57

Constant + time

τ_{τ}

25	-4.38	-3.95	-3.60	-3.24
50	-4.15	-3.80	-3.50	-3.18
100	-4.04	-3.73	-3.45	-3.15
250	-3.99	-3.69	-3.43	-3.13
500	-3.98	-3.68	-3.42	-3.13
∞	-3.96	-3.66	-3.41	-3.12

Teste DF no R

Para realizar o teste de Dickey-Fuller, carregue o pacote `urca`.

Em seguida use a função `UR.DF`, a qual retorna, automaticamente, os valores críticos para o teste.

No R as estatísticas são denotadas por:

$$\tau_{\tau} = \tau_3$$

$$\tau_{\mu} = \tau_2$$

$$\tau = \tau_1$$

Significância dos Termos Determinísticos Individuais

EMPIRICAL DISTRIBUTION OF

Sample size n	$\hat{\tau}_{\alpha t}$ FOR $(\alpha, \beta, \rho) = (0, 0, 1)$ IN $Y_t = \alpha + \beta t + \rho Y_{t-1} + e_t$			
	0.90	0.95	0.975	0.99
25	2.77	3.20	3.59	4.05
50	2.75	3.14	3.47	3.87
100	2.73	3.11	3.42	3.78
250	2.73	3.09	3.39	3.74
500	2.72	3.08	3.38	3.72
∞	2.72	3.08	3.38	3.71

$\hat{\tau}_{\beta t}$ FOR $(\alpha, \beta, \rho) = (0, 0, 1)$ IN $Y_t = \alpha + \beta t + \rho Y_{t-1} + e_t$

25	2.39	2.85	3.25	3.74
50	2.38	2.81	3.18	3.60
100	2.38	2.79	3.14	3.53
250	2.38	2.79	3.12	3.49
500	2.38	2.78	3.11	3.48
∞	2.38	2.78	3.11	3.46

$\hat{\tau}_{\alpha \rho}$ FOR $(\alpha, \rho) = (0, 1)$ IN $Y_t = \alpha + \rho Y_{t-1} + e_t$

25	2.20	2.61	2.97	3.41
50	2.18	2.56	2.89	3.28
100	2.17	2.54	2.86	3.22
250	2.16	2.53	2.84	3.19
500	2.16	2.52	2.83	3.18
∞	2.16	2.52	2.83	3.18

Significância dos Termos Determinísticos

Análise da significância dos elementos determinísticos (constante e tendência linear) por meio de testes de hipóteses conjuntos, utilizando valores críticos simulados por DF.

Dickey & Fuller (1981) sugerem as estatísticas F denominadas ϕ_1 , ϕ_2 e ϕ_3 para testar hipóteses conjuntas:

$$H_0 : \gamma = \alpha = 0 \Rightarrow \Phi_1$$

$$H_0 : \gamma = \alpha = \beta = 0 \Rightarrow \Phi_2$$

$$H_0 : \gamma = \beta = 0 \Rightarrow \Phi_3$$

As estatísticas relacionadas a essas hipóteses são:

$$\phi_i = \frac{(SQRes_{restrita} - SQRes_{irrestrita})/r}{SQRes_{irrestrita}/(T - k)} \quad i = 1, 3$$

sendo r o número de restrições, T número de observações, k número de parâmetros estimados no modelo irrestrito.

EMPIRICAL DISTRIBUTION OF

Φ_1 FOR $(\alpha, \rho) = (0, 1)$ IN $Y_t = \alpha + \rho Y_{t-1} + e_t$

Sample size n	0.90	0.95	0.975	0.99
25	4.12	5.18	6.30	7.88
50	3.94	4.86	5.80	7.06
100	3.86	4.71	5.57	6.70
250	3.81	4.63	5.45	6.52
500	3.79	4.61	5.41	6.47
∞	3.78	4.59	5.38	6.43

Φ_2 FOR $(\alpha, \beta, \rho) = (0, 0, 1)$ IN $Y_t = \alpha + \beta t + \rho Y_{t-1} + e_t$

25	4.67	5.68	6.75	8.21
50	4.31	5.13	5.94	7.02
100	4.16	4.88	5.59	6.50
250	4.07	4.75	5.40	6.22
500	4.05	4.71	5.35	6.15
∞	4.03	4.68	5.31	6.09

Φ_3 FOR $(\alpha, \beta, \rho) = (\alpha, 0, 1)$ IN $Y_t = \alpha + \beta t + \rho Y_{t-1} + e_t$

25	5.91	7.24	8.65	10.61
50	5.61	6.73	7.81	9.31
100	5.47	6.49	7.44	8.73
250	5.39	6.34	7.25	8.43
500	5.36	6.30	7.20	8.34
∞	5.34	6.25	7.16	8.27

2. Testes Dickey Fuller Aumentado – ADF

Resíduos $\hat{\epsilon}_t$ obtidos dos modelos (1) a (3) são ruídos brancos?

Teste ADF: adiciona as defasagens da variável dependente, ou seja, supõe-se que a série é gerada por um processo auto-regressivo de ordem p .

$$(4) \quad \Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^{p-1} \delta_i \Delta Y_{t-i} + \epsilon_t$$

$$(5) \quad \Delta Y_t = \alpha + \gamma Y_{t-1} + \sum_{i=1}^{p-1} \delta_i \Delta Y_{t-i} + \epsilon_t$$

$$(6) \quad \Delta Y_t = \gamma Y_{t-1} + \sum_{i=1}^{p-1} \delta_i \Delta Y_{t-i} + \epsilon_t$$

Inclusão de termos autorregressivos não altera a convergência das estatísticas τ , τ_μ e τ_τ . Portanto, usa-se nos testes ADF os mesmo valores críticos utilizados nos testes DF.

Para identificar o número de atrasos p de forma que $\hat{\epsilon}_t \sim RB(0, \sigma_\epsilon^2)$, usa-se:

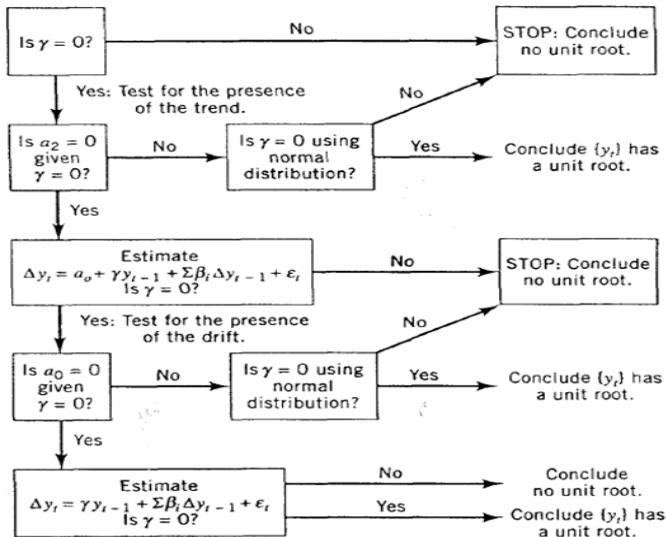
- 1) análise das autocorrelações dos resíduos do modelo sem termos de aumento;
- 2) critérios de informação: Akaike (AIC) ou Bayesian (BIC):

$$AIC(p) = \ln(\sigma_\epsilon^2) + p \frac{2}{T}$$

$$BIC(p) = \ln(\sigma_\epsilon^2) + p \frac{\ln(T)}{T}$$

em que T é o número de observações e p número de parâmetros.

Figure 4.7 A procedure to test for unit roots.
 Estimate $\Delta y_t = a_0 + \gamma y_{t-1} + a_2 t + \sum \beta_i \Delta y_{t-i} + \varepsilon_t$



Exemplo

Verificar a existência de RU para:

1. IPCA dessazonalizada (Fonte: IPEADATA).
2. Taxa de Câmbio médio *Real/US\$* (Fonte: IPEADATA).

Poder do Teste de Dickey-Fuller

Erro Tipo I: probabilidade de rejeitar a hipótese nula quando esta hipótese é verdadeira.

Erro Tipo II: probabilidade de não rejeitar a hipótese nula quando a hipótese alternativa é verdadeira.

Poder do Teste: é calculado como 1 menos a probabilidade de se cometer um erro do tipo II, isto é, a probabilidade de se rejeitar a hipótese nula quando ela efetivamente é falsa.

Poder do Teste de Dickey-Fuller

Poder dos testes DF e ADF: em geral, é pequeno devido a alta persistência e/ou tendência presente nas variáveis macroeconômicas.

Consequência: muitas vezes tendemos a aceitar a existência de uma raiz unitária quando na verdade deveríamos rejeitá-la.

Teste DF assume que os resíduos são não correlacionados, sendo que uma maneira de garantir isso é a de incluir defasagens das diferenças da variável dependente na regressão de teste, isto é, aplicar o teste ADF.

Ao se incluir um número maior de regressores que não estão presentes no processo da série, somente agrava o problema.

Teste de Phillips-Perron (PP)

Phillips & Perron (1988) propuseram uma estatística de teste não paramétricas em que a hipótese nula de uma raiz unitária, explicitamente permite dependência fraca e heterogeneidade do processo de erro.

O teste é baseado nas respectivas estatísticas:

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \epsilon_t \quad \rightarrow \quad Z_{\tau, \beta}$$

$$\Delta Y_t = \alpha + \gamma Y_{t-1} + \epsilon_t \quad \rightarrow \quad Z_{\tau, \mu}$$

$$\Delta Y_t = \gamma Y_{t-1} + \epsilon_t \quad \rightarrow \quad Z_{\tau}$$

Obtenção das estatísticas $Z_T, Z_{T,\mu}, Z_{T,\beta}$ depende do cálculo da variância de longo prazo dos resíduos:

$$\hat{v}^2 = \hat{\sigma}^2 + \frac{2}{T} \sum_{j=1}^M \omega\left(\frac{j}{M+1}\right) \sum_{t=j+1}^T \hat{\epsilon}_t \hat{\epsilon}_{t-j}$$

sendo $\hat{\sigma}^2$ variância populacional estimada; M tamanho do lag; T tamanho da amostra; $\omega\left(\frac{j}{M+1}\right)$ função de ponderação.

- Cálculo da função de ponderação: proposta por Bartlett, ou Parzen ou Quadrática;
- Perron (1990) recomenda o uso da janela de Parzen.
- Grande parte dos trabalhos empíricos emprega ponderação proposta por Bartlett.
- Determinação de M : critério de Newey-West (1994) ou Andrews (1991).

Phillips & Perron (1988) também definiram testes sobre os coeficientes do modelo, em vez de usar a estatística t , chamados de z_α . Neste caso, os testes são realizados sobre a distribuição dos coeficientes.

Do ponto de vista prático, não há diferença entre a análise associada às estatísticas ou sobre a distribuição.

Pacote `urca`

- Usa a função `ur.pp()`

```
ur.pp(x, type = c('Z-alpha', 'Z-tau'), model =  
c('constant', 'trend'),  
lags = c('short', 'long'), use.lag = NULL)
```

`Z-alpha` teste sobre os coeficientes do modelo e `Z-tau` teste sobre as estatísticas do modelo (na prática não há diferença);

`short`: truncamento é dado por $\text{trunc}(4 * (n/100)^{1/4})$;

`long`: truncamento é dado por $\text{trunc}(12 * (n/100)^{1/4})$;

`use.lag`: usuário fornece o número de defasagens;

Para correção do termo erro é usado a ponderação de Bartlett.

Exemplo

Verificar a existência de RU para:

1. IPCA dessazonalizada (Fonte: IPEADATA).
2. Taxa de Câmbio médio *Real/US\$* (Fonte: IPEADATA).

Teste de KPSS

Kwiatkowski, Phillips, Schmidt & Shin (1992)¹ desenvolveram um teste de raiz unitária denominado KPSS.

Neste teste as hipóteses são formuladas por:

$$H_0 : \{y_t\} \text{ é } I(0) \quad \Rightarrow \quad \text{A série é estacionária}$$

$$H_1 : \{y_t\} \text{ é } I(1) \quad \Rightarrow \quad \text{A série é não estacionária}$$

Rejeitar H_0 significa que a série tem uma raiz unitária.

¹Kwiatkowski, D., Phillips, P. C. B., Schmidt, P. and Shin, Y. (1992), “Testing the null hypothesis of stationarity against the alternative of a unit root: How sure are we that economic time series have a unit root?”, *Journal of Econometrics*, 54, 159–178.

Teste de KPSS

O teste KPSS é baseado no seguinte modelo:

$$y_t = \delta t + r_t + \epsilon_t \quad (1)$$

$$r_t = r_{t-1} + u_t \quad (2)$$

em que r_t é um passeio aleatório e ϵ_t é um ruído branco com média zero e variância constante. O valor r_0 é fixo e corresponde ao nível da série.

Se $\delta = 0$ o modelo é escrito como uma constante (μ) como termo determinístico.

Se $\delta \neq 0$ o modelo tem uma constante e uma tendência determinística.

Passos do Teste de KPSS

1. Estima-se o modelo representado pela equação (1)
2. Obtém-se os resíduos $\hat{\epsilon}_t$.

3. Calcula-se a soma parcial dos resíduos: $S_t = \sum_{j=1}^t \hat{\epsilon}_j$

4. A estatística do teste é dada por: $KPSS = \frac{\sum_{t=1}^T S_t^2}{\hat{\sigma}_\epsilon^2}$

sendo T o tamanho da amostra, $\hat{\sigma}_\epsilon^2$ a estimativa da variância de ϵ :

$$\hat{\sigma}_\epsilon^2 = \frac{1}{T} \sum_{t=1}^T \hat{\epsilon}_t^2 + \underbrace{\frac{2}{T} \left(\sum_{j=1}^M \omega \left(\frac{j}{M+1} \right) \sum_{t=j+1}^T \hat{\epsilon}_t \hat{\epsilon}_{t-j} \right)}_{\text{correção da autocorrelação residual}}$$

Se KPSS for maior que valor crítico: rejeitar H_0 .

■ Função `ur.kpss()`

```
ur.kpss(y, type = c("mu", "tau"),  
lags = c("short", "long", "nil"), use.lag = NULL)
```

em que `mu` indica o uso do termo constante e `tau` o emprego da constante e tendência.

Para a escolha do número de termos para a correção da autocorrelação dos resíduos temos as opções:

- a) `short` que representa incluir até a defasagem dada pelo valor inteiro de: $4 * \left(\frac{T}{100}\right)^{1/4}$;
- b) `long` que representa incluir até a defasagem dada pelo valor inteiro de: $12 * \left(\frac{T}{100}\right)^{1/4}$;
- c) `nil` significa não fazer nenhuma correção no termo de erro.

O termo `use.lag` permite que o próprio usuário forneça o número de defasagens para a correção da autocorrelação dos resíduos.

Exemplo

Verificar a existência de RU para:

1. IPCA dessazonalizada (Fonte: IPEADATA).
2. Taxa de Câmbio médio *Real/US\$* (Fonte: IPEADATA).